ШКОЛА АНАЛИТИКОВ HH.RU · ЛЕКЦИЯ 2

Домашнее задание

к лекции «Продвинутый SQL»

Учебная база «Рынок IT-вакансий» · максимум 10 баллов

Как выполнять и как сдавать

Продолжим работать с данными сервиса поиска работы, но теперь посмотрим глубже на то, что происходит после отклика кандидата на вакансию.

После получения отклика работодатель может написать кандидату, позвонить ему, использовать оба канала или вообще не выйти на связь. Коммуникаций по одному отклику может быть несколько, а звонки и сообщения хранятся в разных таблицах. Кроме того, исходные данные могут содержать ошибки, пропуски и нетипичные значения.

В этой работе вам предстоит последовательно подготовить данные, восстановить историю коммуникаций и сравнить, как разные работодатели работают с откликами.

Формат сдачи

Один файл `.sql`. Внутри — задания по порядку, каждое начинается комментарием с номером. Под каждым итоговым запросом — указанные в условии контрольные значения и короткий вывод в комментариях:

```
-- ЗАДАНИЕ 1
SELECT ...
FROM ...;

-- Вывод: ...
```

- **Вывод — обязательная часть задания.** Формулировка не оценивается стилистически: проверяется, соответствует ли она полученным расчётам.
- Не создавайте и не изменяйте таблицы в схеме `hh_school`.
- Если в условии сказано «в первые 7 дней после отклика», отсчёт начинается с момента `responses.created_at` и длится 7 суток.
- Все задания — этапы одного исследования. Сохраняйте промежуточные наблюдения: в финальной части нужно будет сопоставить результаты нескольких блоков и самостоятельно решить, какие дополнительные расчёты нужны для ответа на бизнес-вопрос.

СОВЕТ

Придерживайтесь code style из лекции: не используйте `SELECT *` в итоговых запросах, фильтруйте данные до тяжёлых соединений и агрегаций, следите за гранулярностью CTE и используйте понятные алиасы. Все нужные конструкции с примерами собраны в хэндбуке к лекции.

Баллы

Блок	Задание	Баллы
А. Качество и подготовка данных	1. Аудит качества данных	1,5
Б. История коммуникаций	2. Единый слой коммуникаций	0,5
	3. Таймлайн коммуникаций и витрина отклика	1,5
В. Сравнение работодателей	4. Рейтинг работодателей внутри направления	1
	5. Скорость ответа работодателя в переписке	0,5
Г. Сложные типы данных	6. Теги звонков и метаданные сообщений	1
Д. Самостоятельное исследование	7. Что связано с приглашением?	2,5
	8. Итог исследования	1,5
Итого		**10**

Блок А. Качество и подготовка данных

Перед тем как считать метрики, нужно понять, каким данным можно доверять и какие правила подготовки понадобятся дальше.

Справка: перцентили

Перцентили на лекции мы не разбирали, поэтому коротко расскажем здесь. В PostgreSQL есть две функции:

- `PERCENTILE_CONT` может интерполировать значение между соседними наблюдениями;
- `PERCENTILE_DISC` возвращает одно из реально существующих значений выборки.

В продуктовой аналитике для непрерывных величин вроде времени ответа чаще используют `PERCENTILE_CONT`. Пример — медиана (50-й перцентиль) длительности успешного звонка:

```
SELECT
    PERCENTILE_CONT(0.5) WITHIN GROUP (
        ORDER BY call_duration
    ) AS p50_call_duration
FROM calls
WHERE status = 'successful';
```

1. Аудит качества данных · 1,5 балла

Перед расчётом метрик исследуйте таблицы `calls` и `messages` и найдите записи, которые могут исказить дальнейший анализ.

Среди необычных значений могут встречаться как реальные ошибки, так и допустимые бизнес-сценарии. Поэтому недостаточно просто найти редкое или странное значение — нужно понять, влияет ли оно на возможность использовать строку в расчётах.

Самостоятельно определите набор проверок. В частности, подумайте:

- можно ли корректно связать событие с откликом;
- согласуются ли между собой идентификаторы в связанных таблицах;
- может ли событие находиться в указанной точке времени относительно отклика;

- согласуются ли значения внутри одной строки между собой;
- есть ли пропуски в данных, которые понадобятся дальше;
- есть ли значения, заметно отличающиеся от основной массы наблюдений.

Для каждого найденного типа проблемы получите:

- количество строк;
- `call_id` или `message_id` проблемных записей;
- краткий комментарий: влияет ли проблема на сам факт коммуникации или только на отдельный атрибут события.

Отдельно исследуйте `call_duration` успешных звонков. Для строк, где значение длительности можно содержательно интерпретировать, посчитайте:

- среднюю длительность;
- медиану длительности;
- 99-й перцентиль длительности;
- количество звонков выше 99-го перцентиля;
- среднюю длительность после исключения значений выше 99-го перцентиля.

В ВЫВОДЕ

Найденные проблемы и контрольные значения.

Отдельно напишите, считаете ли вы значения выше 99-го перцентиля ошибками или допустимыми выбросами и как поступили бы с ними при расчёте типичной длительности звонка. Сам выбор не влияет на балл: он нужен, чтобы зафиксировать принятое аналитическое решение.

Блок Б. История коммуникаций

Теперь приведём звонки и сообщения к единой структуре и восстановим порядок событий после каждого отклика.

2. Единый слой коммуникаций · 0,5 балла

Соберите единый слой коммуникаций со стороны работодателя, которые произошли в первые 7 дней после отклика.

Решение должно быть декомпозировано с помощью CTE: подготовка исходных таблиц и объединение событий должны быть разделены на понятные логические этапы.

Используйте результаты аудита из задания 1 и не включайте в аналитический слой события, которым нельзя доверять именно как факту коммуникации после конкретного отклика.

Приведите звонки и сообщения к общей гранулярности **одна строка = одно событие**. В результате должны быть минимум:

- `response_id`;
- `employer_id`;
- `event_id`;
- `event_at`;
- `event_type` — `call` или `message`.

Итоговым запросом получите четыре контрольных значения:

- общее количество событий;

- количество различных откликов с коммуникацией;
- количество звонков;
- количество сообщений.

В КОММЕНТАРИИ

Все четыре числа.

3. Таймлайн коммуникаций и витрина отклика · 1,5 балла

На основе единого слоя событий восстановите последовательность коммуникаций внутри каждого `response_id`.

Шаг 1. Слой уровня события

Для каждого события, **не меняя гранулярность таблицы**, определите:

- порядковый номер события внутри отклика;
- время предыдущего события;
- тип следующего события;
- количество коммуникаций от начала истории до текущего события включительно;
- тип первой коммуникации по отклику;
- тип последней коммуникации по отклику.

Если несколько событий имеют одинаковое время, используйте дополнительный устойчивый порядок: сначала `event_type`, затем `event_id`.

Шаг 2. Витрина уровня отклика

Соберите витрину, где **одна строка = один** `response_id`**. В ней должны быть минимум:**

- `response_id`, `employer_id`, `professional_role`;
- статус отклика;
- количество коммуникаций, звонков и сообщений;
- время первой коммуникации;
- тип первой, второй и последней коммуникации;
- время от отклика до первой коммуникации в часах;
- максимальный интервал между соседними коммуникациями в часах.

ПОДВОДНЫЙ КАМЕНЬ

Отклики без коммуникаций **не должны исчезать** из витрины.

В конце отдельным запросом по витрине получите:

- количество строк;
- количество откликов с коммуникацией;
- количество откликов без коммуникации;
- количество откликов, где первой коммуникацией было сообщение;
- количество откликов, где первой коммуникацией был звонок.

В КОММЕНТАРИИ

Все пять контрольных значений.

Блок B. Сравнение работодателей

Используем собранную витрину, чтобы сравнить обработку откликов и скорость коммуникации.

4. Рейтинг работодателей внутри направления · 1 балл

Используя витрину из задания 3, для каждой пары `professional_role` + `employer_id` посчитайте:

- количество откликов;
- количество откликов с коммуникацией в первые 7 дней;
- долю таких откликов в процентах;
- медиану времени до первой коммуникации (по откликам, где коммуникация была);
- 90-й перцентиль времени до первой коммуникации (по тем же откликам);
- конверсию отклика в приглашение в процентах.

В рейтинг включайте только пары, где есть **не менее 8 откликов**. Внутри каждого профессионального направления присвойте работодателям место по правилам:

1. выше находится работодатель с большей долей обработанных откликов;
2. при равенстве выше находится работодатель с меньшей медианой времени до первой коммуникации;
3. одинаковым значениям обоих критериев соответствует одинаковое место, а следующее место идёт без пропуска номера.

Оставьте только работодателей, занявших 1-е или 2-е место в своём направлении.

В КОММЕНТАРИИ

`professional_role`, место и `employer_id` всех строк итогового результата.

5. Скорость ответа работодателя в переписке · 0,5 балла

Используйте сообщения, которые можно корректно связать с откликом и которые произошли в первые 7 дней после него.

Для каждого сообщения определите, кто и когда отправил предыдущее сообщение в рамках того же отклика. Затем найдите случаи, когда сообщение работодателя идёт **непосредственно после** сообщения кандидата, и для каждой такой пары посчитайте время ответа работодателя в часах.

После этого для каждого работодателя посчитайте:

- количество измеренных ответов;
- среднее время ответа;
- медиану времени ответа;
- 90-й перцентиль времени ответа.

Отсортируйте результат по медиане времени ответа по возрастанию.

В КОММЕНТАРИИ

Общее количество найденных ответов;

`employer_id` работодателя с минимальной медианой;

значение его медианы.

Блок Г. Сложные типы данных

Часть информации о коммуникациях хранится не в отдельных колонках, а внутри массивов и JSON.

6. Сложные типы данных · 1 балл

6.1. Теги звонков

Для звонков работодателя в первые 7 дней после отклика исследуйте `call_tags` как массив, **не преобразуя его целиком в строку**.

Сначала проверьте, согласуются ли технические теги звонка с его `status`. Строки с противоречием не должны участвовать в статистике по тегам. После этого получите количество звонков для каждого из бизнес-тегов:

- `screening`;
- `interview`;
- `follow_up`;
- `details`.

Дополнительно посчитайте:

- количество валидных звонков, содержащих хотя бы один из перечисленных бизнес-тегов;
- среднее количество тегов на один валидный звонок.

> **В КОММЕНТАРИИ**
> Все полученные значения.

6.2. Метаданные сообщений

Для сообщений работодателя в первые 7 дней после отклика извлеките из `message_meta`:

- канал отправки;
- признак прочтения;
- количество вложений.

Для каждого канала посчитайте:

- количество сообщений;
- количество сообщений, где признак прочтения присутствует;
- количество непрочитанных сообщений;
- долю непрочитанных среди сообщений, где признак прочтения известен;
- количество сообщений хотя бы с одним вложением;
- долю сообщений с вложением.

Если канал в метаданных отсутствует, выделите такие сообщения в отдельную группу.

> **В КОММЕНТАРИИ**
> Контрольные значения по всем получившимся каналам.

Блок Д. Самостоятельное исследование

До этого набор показателей был в основном задан условием. Теперь нужно самостоятельно определить, какие расчёты помогут ответить на бизнес-вопрос, и связать их с результатами предыдущих этапов.

7. Что связано с приглашением? · 2,5 балла

Команда продукта хочет понять, отличаются ли коммуникации по откликам, которые заканчиваются приглашением, от коммуникаций по остальным откликам — и если отличаются, то чем именно.

До написания SQL сформулируйте в комментариях **две проверяемые гипотезы**. Затем самостоятельно решите, какие показатели и разрезы нужны для их проверки. Требования к исследованию:

- для проверки используйте не менее трёх характеристик коммуникации;
- характеристики должны описывать как минимум два разных аспекта коммуникации;
- как минимум один расчёт должен быть новым: такой показатель или разрез не должен быть напрямую запрошен в заданиях 1–6;
- для каждой сравниваемой группы показывайте количество откликов, на котором рассчитаны показатели;
- каждая гипотеза должна завершаться выводом «подтверждается», «не подтверждается» или «данных недостаточно» и опираться на конкретные числа.

> **ПОДВОДНЫЙ КАМЕНЬ**
> Простое повторение контрольных показателей или рейтингов из предыдущих заданий **без нового расчёта** не засчитывается как самостоятельное исследование.

8. Итог исследования · 1,5 балла

Представьте, что результаты работы нужно передать продакт-менеджеру. На основе заданий 1–7 сформулируйте единый итог исследования в **7–10 предложениях**. В итоговом выводе обязательно должны быть:

- не менее четырёх конкретных числовых результатов минимум из трёх разных заданий;
- вывод о том, как в целом работодатели взаимодействуют с откликами после их получения;
- вывод о различиях между работодателями или профессиональными направлениями;
- вывод о том, какие особенности коммуникации связаны с приглашением по результатам задания 7;
- минимум одно ограничение проведённого анализа;
- один следующий исследовательский вопрос: что ещё вы бы посчитали или какие дополнительные данные запросили бы, чтобы лучше понять коммуникацию после отклика.

> **СОВЕТ**
> Не нужно пересказывать все таблицы по порядку. Итог должен **связывать отдельные расчёты в одну картину** и отделять наблюдаемую связь от причинно-следственного вывода.